

IMSAF based RIR tracking

Michele Sulis

Mauro Michele Maria Costantino

28 giugno 2026

1 Introduzione

Questo documento raccoglie, in forma cronologica, lo sviluppo e la sperimentazione di un algoritmo di stima e tracciamento della risposta impulsiva della stanza, o Room Impulse Response (RIR) basato su filtraggio adattativo in sottobande, nel contesto dei sistemi di Sound Field Control (SFC) [1, 2].

L'algoritmo di riferimento appartiene alla famiglia Improved Multiband-Structured Subband Adaptive Filter (IMSAF): il segnale di eccitazione e i segnali captati dai microfoni vengono decomposti in sottobande tramite un *banco filtri DFT*, e in ciascuna sottobanda un filtro adattativo di tipo Normalized Least Mean Square (NLMS) stima la porzione corrispondente della RIR. La struttura in sottobande riduce la correlazione del segnale in ingresso e accelera la convergenza rispetto a un adattamento a banda piena.

Il lavoro è organizzato seguendo l'ordine cronologico delle implementazioni realizzate. Si parte da una configurazione Single-Input Single-Output (SISO) (un altoparlante, un microfono) per validare il banco filtri e la ricostruzione della RIR, confrontando diverse scelte di filtro prototipo. Si estende al caso Multiple-Input Multiple-Output (MIMO) (più altoparlanti, più microfoni), affrontando il problema della correlazione tra i canali di eccitazione e le tecniche di decorrelazione necessarie a una stima accurata.

2 Simulazioni (MATLAB)

2.1 Caso SISO

Nel caso SISO il sistema dispone di un singolo altoparlante e di un singolo microfono. Questa configurazione, pur non rappresentando lo scenario applicativo finale, consente di isolare e validare due aspetti fondamentali: il grado di trasparenza del banco filtri di analisi/sintesi e l'accuratezza della ricostruzione della RIR a banda piena a partire dalle componenti in sottobanda. In particolare, si confrontano due scelte di filtro prototipo per il banco DFT.

2.1.1 Filtri prototipo

Si confrontano due prototipi: un filtro passa-basso progettato con `fir1` (finestra di Kaiser) e un filtro a coseno rialzato.

Entrambi i prototipi sono progettati per suddividere la banda in $I = 64$ sottobande e, per garantire un confronto equo, hanno la stessa lunghezza di 1025 campioni. Il filtro di Kaiser (Figura 1, curva blu) è stato ottenuto con $\beta = 1$, mentre il coseno rialzato (Figura 1, curva arancio) con $\beta = 0.6$ e `span` pari a 16.




Figura 1: Risposta in frequenza (modulo) dei due prototipi a confronto, entrambi di lunghezza 1025 campioni.

2.1.2 Confronto dei risultati

Normalized misalignment (NM) A parità di lunghezza dei due prototipi, il NM evidenzia un comportamento nettamente diverso (Figura 2). Con il coseno rialzato il NM decresce in modo regolare lungo tutta la durata dell’adattamento, scendendo fino a circa -40 dB. Con il prototipo Kaiser, invece, la curva tende a spianare verso un valore limite più alto, attorno a -20 dB.

Poiché i due filtri hanno la stessa lunghezza, la differenza di prestazioni non è attribuibile a tale fattore, bensì alle proprietà del prototipo. Da un lato, il coseno rialzato presenta una transizione più ripida (Figura 1) che riduce la sovrapposizione tra sottobande adiacenti e quindi l’aliasing; dall’altro, soddisfa la condizione di complementarità in potenza, per cui la somma dei moduli quadri delle risposte è prossima a una costante, garantendo una ricostruzione fedele del segnale che transita il banco. Il filtro di Kaiser, non essendo progettato per soddisfare tale condizione, introduce invece un errore di ricostruzione residuo.

Si è inoltre osservato che il filtro di Kaiser risulta fortemente sensibile alla scelta dei suoi parametri (ordine e β): piccole variazioni producono spostamenti significativi del floor del NM, talora con filtri di lunghezza maggiore che forniscono prestazioni peggiori. L’individuazione di una configurazione adeguata richiede una ricerca per tentativi, mentre il coseno rialzato garantisce una ricostruzione accurata senza necessità di tuning.

Il banco basato sul coseno rialzato presenta quindi un comportamento complessivamente più regolare e prevedibile. Le simulazioni sono state condotte assumendo una frequenza di campionamento $f_s = 16$ kHz.




Figura 2: Confronto del normalized misalignment tra i due prototipi, a parità di lunghezza (1025 campioni).

RIR nel dominio del tempo Nel dominio del tempo (Figura 3) la RIR ricostruita con il coseno rialzato risulta praticamente sovrapposta a quella reale, al punto da essere indistinguibile. La stima ottenuta con il prototipo Kaiser se ne discosta leggermente, ma le differenze nel dominio del tempo non sono particolarmente marcate. Tale discrepanza emerge invece in modo più evidente nel dominio della frequenza, discusso di seguito.

Le RIR considerate hanno una lunghezza di 128 campioni, coerentemente con quanto fatto in letteratura [1].




Figura 3: Confronto nel dominio del tempo tra la RIR reale e le RIR stimate con i due prototipi.

RIR nel dominio della frequenza Nel dominio della frequenza (Figura 4) si apprezza meglio la differenza tra i due prototipi. Il modulo della RIR stimata con il coseno rialzato si sovrappone fedelmente a quello della RIR reale su tutta la banda. La stima ottenuta con il prototipo Kaiser ne segue solo l'andamento generale discostandosi visibilmente lungo l'intero spettro, mostrando le deviazioni più marcate oltre i 6.7 kHz.




Figura 4: Confronto nel dominio della frequenza tra la RIR reale e le RIR stimate con i due prototipi.

Conclusioni Dopo aver sperimentato diversi filtri prototipo per il banco e ottimizzato i parametri, si è osservato che il banco basato su un prototipo a coseno rialzato fornisce un comportamento più regolare e prevedibile rispetto al prototipo `fir1`, permettendo di scendere fino a circa -40 dB. Pertanto, a partire dalle sezioni successive, si adotterà esclusivamente il coseno rialzato con $\beta = 0.6$ e `span` pari a 16.

2.2 Caso MIMO

Nel caso MIMO il sistema dispone di L altoparlanti e M microfoni. Ogni microfono capta la somma dei contributi di tutti gli altoparlanti, ciascuno filtrato dalla rispettiva RIR. L'obiettivo è stimare separatamente tutte le $M \times L$ risposte dell'impulso. Il problema principale è l'*identificabilità*: se i segnali inviati ai diversi altoparlanti sono troppo correlati tra loro, non è possibile separare univocamente i singoli percorsi acustici a partire dalle sole osservazioni dei microfoni. Le seguenti sezioni analizzano questo problema e le tecniche di decorrelazione adottate per affrontarlo.

2.2.1 Ingressi scorrelati: caso ideale

Come primo passo si considera il caso in cui i segnali di eccitazione dei diversi canali siano statisticamente indipendenti (rumore bianco generato indipendentemente per ogni altoparlante). Questa configurazione non corrisponde allo scenario reale, ma rappresenta il caso ideale in cui il problema di identificabilità è risolto per costruzione: serve a verificare che la struttura dell'algoritmo di tracciamento MIMO sia corretta.

In queste condizioni il NM (Figura 5) converge rapidamente verso valori molto bassi.




Figura 5: NM nel caso MIMO con ingressi scorrelati (caso ideale). Frequenza di campionamento $f_s = 16$ kHz.

2.2.2 Correlazione realistica tra canali

Nello scenario realistico, in assenza del blocco SFC, un'unica sorgente viene replicata sui diversi canali, che risultano quindi fortemente correlati. Per ripristinare l'identificabilità si applica una decorrelazione mediante *modulazione di fase* in sottobanda, secondo lo schema riportato in letteratura [1]: ogni sottobanda di ciascun canale viene modulata da una fase sinusoidale dipendente dal canale e dall'indice sottobanda.

In queste condizioni il NM (Figura 6) raggiunge un valore limite (*floor*) significativamente più alto rispetto al caso ideale (circa -9 dB). Questo comportamento si interpreta osservando che la modulazione di fase agisce esclusivamente sulla fase del segnale e non sul suo modulo: due canali che partono identici mantengono, dopo la modulazione, lo stesso spettro di ampiezza, restando quindi coerenti in modulo. Con RIR reali, il cui spettro di ampiezza presenta una struttura ricca

e informativa, questa coerenza residua di modulo limita la capacità di separare i canali, fissa un floor più elevato sull'errore e rallenta la velocità di convergenza.




Figura 6: NM nel caso MIMO con canali correlati e decorrelazione tramite modulazione di fase. Frequenza di campionamento $f_s = 16$ kHz.

2.2.3 Ruolo della decorrelazione intra-canale (P)

Oltre alla decorrelazione tra canali (modulazione di fase), l'algoritmo IMSAF prevede una decorrelazione *intra-canale* basata su una predizione lineare di ordine P , che sbianca il segnale di ingresso di ciascun canale. Con eccitazione a rumore bianco l'effetto di tale stadio non è rilevabile, poichè il segnale è già spettralmente piatto. Per evidenziarne il ruolo si è quindi utilizzato come ingresso un rumore colorato, ovvero a spettro non piatto.

I risultati mostrano che la decorrelazione intra-canale **accelera la velocità di convergenza senza modificare il floor** del NM. A titolo di esempio, nel caso a canali scorrelati il NM raggiunge -55 dB dopo 383 iterazioni con $P = 0$ e dopo sole 82 iterazioni con $P = 2$ (circa 4.7 volte più veloce), con floor finali paragonabili. Questo conferma quanto riportato in letteratura [1]: lo sbiancamento dell'ingresso migliora la velocità di adattamento ma non il livello di errore a regime, che dipende da altri fattori (tra cui aliasing del banco, identificabilità).

2.2.4 Segnali reali e gestione pratica

Il passaggio da segnali sintetici a segnali audio reali introduce alcune problematiche pratiche, affrontate con due accorgimenti. In primo luogo, la regolarizzazione nel calcolo dei pesi sotto-banda è stata resa proporzionale all'energia massima delle sottobande, anziché fissa, per garantire robustezza al variare del segnale. In secondo luogo, i campioni a energia molto bassa (silenzii, frequenti nei segnali reali) vengono saltati nell'aggiornamento del filtro, poichè la normalizzazione su ingresso quasi nullo porterebbe l'algoritmo a divergere.

Si è inoltre confrontato l'uso di un canale mono replicato su tutti i canali con quello di un segnale stereo inviato a canali distinti. Il caso stereo fornisce prestazioni migliori poiché i canali sono già intrinsecamente diversi all'origine e parte del problema di identificabilità risulta attenuato a monte. Il segnale stereo reale rappresenta quindi un caso intermedio tra mono replicato (canali identici, caso peggiore) e ingressi indipendenti (caso ideale).

Entrambi i segnali sono stati reperiti dal database pubblicato in [3]. Nello specifico, come segnale mono si è scelta la traccia `50.flac` (Male Speech (English)), e come segnale stereo si è scelta la traccia `69.flac` (ABBA). Nei due casi presi in esame si sono impostati i seguenti parametri

- $I = 8, D = 2$;
- $L = 2, M = 2$;
- $P = 2$;
- $\mu_h = 0.32, \delta_h = 0.001$

e come filtro prototipo si è usato un filtro a coseno rialzato con $\beta = 0.6$ e `span` pari a 16, per un totale di 129 campioni.

Come si nota dalle Figure 7, 8, il fatto che i due canali trasmettano esattamente lo stesso segnale limita fortemenete le prestazioni dell'algoritmo, introducendo una distorsione considerevole della RIR alle basse e alle alte frequenze.




Figura 7: NM nel caso MIMO con ingresso mono replicato sui canali.




Figura 8: Modulo della trasformata della RIR reale (blu) e stimata (arancio) con ingresso mono replicato sui canali.

Al contrario, le Figure 9, 10 evidenziano che, quando i segnali trasmessi sui canali sono diversi (seppur leggermente, come avviene nel caso di due componenti di un segnale stereo), le operazioni di decorrelazione hanno un risultato migliore e portano a tracking molto più accurati. In questo caso, infatti, il confronto tra le Figure 7 e 9 mostra che con segnali diversificati il NM scende regolarmente allo scorrere dei campioni. Inoltre, dalle Figure 8 e 10 si evince che il contenuto spettrale della RIR ricostruita con segnali stereo risulta essere molto più vicino a quello della RIR reale, introducendo un significativo miglioramento nel tracking delle basse frequenze. Anche il tracking delle alte frequenze migliora notevolmente ma continua a soffrire il fatto che i segnali di ingresso, in quanto segnali audio reali, sono tipicamente passa-basso e, per tale ragione, le loro sottobande relative alle frequenze più alte hanno energie molto basse.




Figura 9: NM nel caso MIMO con ingresso stereo diversificato sui canali.




Figura 10: Modulo della trasformata della RIR reale (blu) e stimata (arancio) con ingresso stereo diversificato sui canali.

Riferimenti bibliografici

- [1] J. Zhang, J. Xie, D. Shi, W. Zhang, J. Chen, and J. Benesty, “An alternating mode strategy for adaptive sound field control and acoustic path tracking,” in *2025 Asia Pacific Signal and Information Processing Association Annual Summit and Conference (APSIPA ASC)*, pp. 417–422, 2025.
- [2] J. Zhang, J. Xie, D. Shi, W. Zhang, J. Chen, and J. Benesty, “Decorrelation-enhanced multiband subband adaptive filtering for rir tracking in sound field control,” in *ICASSP 2026 - 2026 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pp. 15052–15056, 2026.
- [3] European Broadcasting Union, “Sound quality assessment material (SQAM) audio database.” <https://ebu.ch>, 2008. Available in FLAC format. Accessed: June 2026.